TFG Jorge Lorente · Pilar 2 — Análisis del Dato

Entrenamiento y evaluación de cuatro modelos sobre el dataset maestro

PREPARACIÓN DE LOS DATOS

dataset_maestro.csv
14.091 × 37

- 1.1 Carga del dataset maestro
- 1.2 Selección de 15 features predictoras
- 1.3 Validación anti data leakage
- 1.4 Train/test split temporal (junio 2024)

TAREA A · CLASIFICACIÓN DEL RIESGO DE CAÍDA

Modelo A — Logistic Regression

- 2.1 StandardScaler sobre features
- 2.2 Fit con class_weight='balanced'
- 2.3 Predicciones y probabilidades
- 2.4 Cálculo de métricas
- 2.5 F1 = 0,331 · AUC = 0,638

Modelo B — Random Forest

- 3.1 Sin necesidad de escalado
- 3.2 Fit con 300 árboles y class_weight='balanced'
- 3.3 Predicciones y probabilidades
- 3.4 Feature importance (Gini)
- 3.5 F1 = 0,070 · AUC = 0,627

TAREA B · PREDICCIÓN DEL PRECIO (BBVA)

Modelo A — ARIMA

- 4.1 ADF test de estacionariedad
- 4.2 Diferenciación de primer orden
- 4.3 Selección del orden por AIC → (2,1,2)
- 4.4 Rolling forecast con refit cada 20
- 4.5 MAE = 0,52 €

Modelo B — LSTM

- 5.1 MinMaxScaler sobre el conjunto de train
- 5.2 Construcción de sequences (60 días)
- 5.3 LSTM stack con Dropout y Dense
- 5.4 Adam + MSE + EarlyStopping
- 5.5 MAE = 3,08 € (discusión honesta)

VISUALIZACIÓN · INTERPRETACIÓN · ENTREGABLES

FIGURAS GENERADAS

- 6. Confusion matrices
- 7. ROC curves
- 8. Feature importance RF
- 9. Logistic coefficients
- 10. ARIMA forecast
- 11. LSTM learning curves
- 12. LSTM predictions

HALLAZGOS PRINCIPALES

- Las variables macro dominan
- Logistic > Random Forest en F1
- Momentum → mean reversion
- VIX alto → menor riesgo
- LSTM con distribution shift
- AUC 0,64 realista y coherente

ARCHIVOS

- **predicciones** clasificación
- **predicciones** ARIMA BBVA
- **predicciones** LSTM BBVA

LEYENDA

- EXTRACCIÓN
- LIMPIEZA
- TRANSFORMACIÓN
- ANÁLISIS